FinReport 上市公司财务报告分析研发项目计划书

项目方向：2026 年北京市大学生金融人工智能竞赛“上市公司财务报告分析”

计划书基线：2026 年 10 月 18 日

项目状态：可运行原型与受限样本验证阶段

一 项目摘要

FinReport 面向 A 股上市公司年度、半年度和季度财务报告，建设一套能够从原始披露材料提取财务事实、保存经营叙述、执行口径受控的本地计算，并让大语言模型按需检索证据、解释业绩变化和提示异常线索的分析系统。目标不是让模型一次性阅读整本报告后直接给出结论，而是把长报告、财务表格和叙述性附注保存在项目控制的数据层中，由分析流程围绕具体问题调用受限的检索、事实、比较和补件工具。

本项目针对赛题考察的同比与环比、非经常性损益、会计口径变化、利润与现金流背离等问题，正式版目标采用“原始披露—候选数据—自动校验与候选标记—确定性计算—证据检索—分项分析—报告呈现”的流程。金额、单位、期间、合并范围、来源页和校验状态随事实一起保存；财务公式由程序执行；模型负责组织分析问题、查找相关材料和解释证据关系。对现有材料无法确认的事项，系统明确列出证据边界与待补材料，不把“未检索到”写成“公司没有披露”，也不把质量检查通过写成“公司没有财务异常”。

截至本计划书基线，项目已有桌面端、API、提取和分析流程、财务公式、SQLite 证据存储、Qdrant MCP 检索及本地 Unlimited-OCR 部署。当前验证集中于比亚迪 2025 年半年度报告的 7 个选定页，以及四份 2025 年报告的少量检索页。固定选页试验最终形成 3 项待校验候选、5 项证据不足，尚无测试金标准评测记录；这说明流程能够保留校验缺口与证据边界，不代表完整报告已分析或赛题要求已全部验收。本计划书将后续工作拆为 WP0-WP10 工作包和 G0-G7 退出
Gate，优先完成全文、多发行人、测试金标准评估、误差归因和演示环境复现评测。

本计划所称测试金标准评估，均仅用于评测与误差归因，不属于正式运行流程。自动校验准入与四类校验状态是 WP4 的研发目标，历史选页实验按原流程记录，不作为新校验状态机已实现的证据。

二 项目背景与问题定义

上市公司财报同时包含结构规则不同的报表、复杂表格、管理层讨论、会计政策和重要事项附注。单纯抽取可见数字会丢失主体、期间、单位、合并范围、调整关系及表格行列关系；直接要求大语言模型总结长文又容易遗漏材料、混淆报告版本或生成没有来源支持的因果解释。同比和环比还依赖报告期间及累计口径，半年度或前三季度的累计数不能直接当作单季度数据比较。

本项目将问题拆成四类可检验工作：

1. **材料与版本管理。** 保留原始 PDF、文件哈希、报告类型和期间；更正稿及不同季度报告作为独立版本管理，分析范围由用户显式选择。
2. **事实提取与口径确认。** 分离结构化金额事实和非结构化披露文本，保存来源定位、单位、期间、主体和校验状态；解析候选不自动成为自动校验通过事实。
3. **程序化计算与异常识别。** 以自动校验通过且来源可追溯的同口径事实计算指标与期间变化，再结合规则和披露证据识别需要解释的异常信号。
4. **证据驱动的解释。** 让模型按子问题查询本地材料和计算记录。证据不足时请求具体文件、期间或附注，不推断缺失材料的内容。

三 项目目标与范围

3.1 项目目标

- 支持年度、半年度和季度报告的分版本入库、页选择、文本及金额候选提取。
- 同时保存结构化事实和可检索的叙述性证据，确保结论可回到报告原文。
- 计算有明确公式、期间和口径的财务指标及同比、环比变化；对负数基期、零分母、缺少比较期或口径不一致给出明确状态。
- 围绕非经常性损益、会计政策或估计变化、前期差错与重述、合并范围、持续经营、利润与经营现金流背离建立分项分析任务。
- 输出结构化结果或分析报告，并区分公司披露、程序计算、分析推断、待校验候选和证据不足。
- 保存运行输入、访问文件、检索与工具调用、原始模型响应、计算记录、源码/依赖版本和结果哈希，支持离线回放。

3.2 当前范围

首期面向中国 A 股非金融企业。严格数值通路优先覆盖人民币、合并口径、完整自然年度及具有标准无保留审计意见的高保证样本；非标准审计意见保留原文和审计意见状态并标记为受限，后续 WP5/WP7 将其作为异常或风险披露纳入分析，不因意见类型而静默丢弃。半年度、季度、选页和 OCR 数据可进入补充分析流程，但未通过自动校验时不得冒充自动校验通过的严格事实。

系统用于财报研究与风险线索整理，不构成证券投资建议，不自动给出买卖结论，也不替代审计、法律、合规或投资决策。若选用外部模型服务，实际发送给模型的文字和页面范围取决于配置；演示阶段须使用获准样本、记录模型服务及版本，并遵守组委会对数据环境的具体要求。

四 赛题要求映射

赛题要求	研发方案	覆盖状态	验收证据/下一 Gate
从年报、半年报、季报提取指标	按披露文件和期间保存版本，原生 PDF 与 OCR 两种路径生成候选数据，记录金额、单位和来源	受限验证	G1-G2：全文样本、结构指标和来源定位评测
同比、环比计算准确	财务公式模块强制校验币种、主体、合并范围、累计/单季口径和期间；异常分母或缺失比较期时拒算	已有原型/受限验证	G3：独立参考实现和多报告测试金标准
业绩变化原因及异常信号	按收入利润、费用、资产负债、现金流、非经常性损益及重要事项拆成子问题，匹配原文和程序计算	受限验证	G4-G5：规则覆盖、证据支持率和误差分类账
非经常性损益	读取构成、扣减、所得税及合计项目，保存逐行依据；与归母净利润、扣非归母净利润进行口径核对	待补测试金标准	G4：完整表格和跨页续表测试
会计口径变化	单独分析政策、估计、前期差错/追溯重述、合并范围及报告版本；附注缺失则列出补件需求	受限验证	G4：附注样本与缺件状态

赛题要求	研发方案	覆盖状态	验收证据/下一 Gate
利润与现金流背离	比较净利润与经营现金流的变化方向、符号及现金利润比，读取可验证调节项和业务解释；区分勾稽关系与经营原因	受限验证	G3-G4：口径校验和原因证据评测
过程可验证、可追溯、可复现	冻结输入哈希、来源页、请求响应、工具参数与结果、公式版本；离线回放保存的输入和响应	已有原型/受限验证	G6-G7：回放和干净环境检查
使用大语言模型完成核心推理	由 OpenAI 兼容 LLM 客户端驱动受控 Agent，按子命题调用检索、事实、比较和补件工具	已有原型	G5：工具轨迹、发送窗口和失败恢复
结果不能只交对话	同时输出结构化事实、程序计算、引用证据、校验状态和分析报告	已有原型/受限验证	G6：报告 schema 和校验日志
数据、工具、计算和生成过程留痕	保存文件/原文哈希、提取方式、工具参数、实际发送窗口、模型原响应、公式版本和结果哈希	已有原型/受限验证	G6：日志完整性和离线检查
源码与演示环境一致	以冻结提交、依赖锁定、配置清单和演示脚本绑定运行版本	待演示验证	G7：干净环境运行和资源记录

覆盖状态记录当前基线；各项是否达到研发目标，以对应 Gate 的样本、规则、日志和评测结果为准。

五 总体方案与系统流程

5.1 正式版目标流程

1. **导入与隔离。** 用户上传财报，系统先执行文件扫描和哈希计算，再按公司、报告期、报告类型和更正关系保存独立版本。默认一次分析针对一份锚定报告；多份报告只有在用户明确勾选时才会组成比较输入。
2. **选择提取路径。** 用户明确选择原生 PDF 文本/坐标提取或 OCR。原生路径读取 PDF 文字层及位置；OCR 路径将选定页渲染为图像，不读取该任务的 PDF 文字层或文字坐标。解析失败不会静默切换路径。
3. **自动校验与候选标记。**
   提取结果先作为候选，执行格式、单位、期间、口径、表格勾稽、来源定位和置信度校验，标记 auto_passed、needs_review、rejected 或 candidate。OCR 表格需要完成行列与科目映射；测试金标准评估仅用于评测自动校验的误放和误拒，不进入正式运行流程。校验状态与原文、页码、坐标或图像哈希绑定，材料变化后原校验结果失效。
4. **结构化与非结构化分离。** 数字、币种、单位、期间、主体、报表范围、科目、来源位置和校验状态进入事实与计算数据；管理层讨论、会计政策、重大事项、业务原因等以原文块保存，附章节、页码、哈希和表格关系供检索。
5. **本地预处理与检索。** 可选 Docling MCP 对已选 PDF 页生成含章节和表格关系的结构化文档。证据块写入 SQLite 权威存储，并可同步到 Qdrant MCP；Qdrant 按报告版本过滤并负责召回，SQLite 保存权威文本和可复核来源。检索服务不可用时可退回确定性关键词查询。
6. **确定性计算。** 严格通路只读取自动校验通过且来源可追溯、口径满足条件的事实。报告金额试验通路可以对候选执行可复算算术，结果标记为 candidate_arithmetic 并继承校验状态，不升级为严格事实。两条通路均保存公式版本、输入来源、比较期间、单位和异常状态；模型不能自行编造或改写程序结果。

7. **分项分析与按需取证。** 语言模型使用有限工具查询文件目录、指定文本块、事实、比较计算或待补材料。系统按子命题处理候选，保存每轮请求、响应、工具参数和准入/拒绝原因；缺失材料时返回 waiting_for_documents 或不完整状态。
8. **报告与结果检查。** 结果按公司披露、程序计算、分析推断、待校验及证据不足分类。每项结论展示引用和适用期间；用户可查看原文或要求补充材料后续分析。

校验状态定义为：candidate 表示尚未完成校验；auto_passed
表示必需规则全部通过且来源可追溯；needs_review
表示来源、结构或口径仍有疑点，保留结果并由补证、重新提取或规则重算处理；rejected
表示违反硬性规则，阻断该候选进入严格计算。needs_review
不设置人员处理的正式准入要求。置信度高或表格合计相符不能单独将事实升级为
auto_passed；自动校验通过也不等于原始披露真实或业务因果已确认。

5.2 系统组成

层次	主要组件	责任
桌面交互	.NET 10 WPF	文件选择、提取方式选择、自动校验状态、分析任务及结果查看
API 与工作流	FastAPI	接收请求、任务状态、接口权限边界、结果和审计记录
领域与应用	Python uv workspace	财务口径、公式、事实准入、分析任务和工作流编排
解析与模型适配	PyMuPDF、Unlimited-OCR、Docling MCP、OpenAI 兼容 LLM 客户端	文本/图像识别、结构化预处理和受控模型调用
本地证据存储	SQLite 与对象目录	权威保存文件信息、事实、文本块、校验日志、计算和回放输入
证据检索	Qdrant MCP	向量召回和报告版本过滤；不承担事实批准或财务计算
文件安全	Rust Scanner Supervisor 与 ClamAV	文件进入解析前执行扫描，扫描错误时阻断处理

当前 API 使用 FastAPI 后台任务执行分析；仓库存在 Celery Worker 组合根，但未完成 Celery/Redis 多进程生产部署验收。系统目前以本地演示配置为主，PostgreSQL 可配置但不代表生产数据库部署已经验证。

5.3 研发任务分解

本项目按工作包（Work Package，WP）管理研发活动。每个工作包单独登记依赖关系、下一 Gate 交付和退出证据。

编号	工作包	当前基线	前置依赖	下一 Gate 交付	退出标准
WP0	基线与研发治理	已有代码路径	无	baseline manifest、代码/配置/依赖清单、风险登记	输入哈希、报告版本和运行命令冻结；保存响应的离线回放可运行
WP1	材料与版本管理	已有代码路径	WP0	corpus manifest、报告版本关系、缺件清单	样本文件均有哈希和期间元数据；未显式选择的报告不会进入检索或计算
WP2	原生 PDF 与 Unlimited-OCR 双路径提取	已有代码路径	WP1	双路径 extraction bundle、页级质量报告	两条路径不静默互相回退；金额、科目结构、单位和期间分层评测

编号	工作包	当前基线	前置依赖	下一 Gate 交付	退出标准
WP3	结构化与非结构化分离	已有代码路径	WP2	fact candidate、table unit、text chunk 和来源映射	严格事实可回到页、文本块或行列；无法闭合的表格只保留候选
WP4	自动校验与测试金标准评估	仅有设计	WP2、WP3	校验规则、测试金标准、误差分类账	格式、单位、期间、口径、勾稽和来源规则覆盖；严格计算只接受 auto_passed；测试金标准样本可评估误放/误拒
WP5	财务口径与确定性计算	已有代码路径	WP3、WP4	fact ledger、calculation ledger、公式版本和边界用例	独立参考实现对照通过；零/负基数、缺比较期和口径不一致时拒算
WP6	证据检索与受控 Agent	已有代码路径	WP1、WP3、WP5	obligation trace、检索基准、补件清单	每项结论有引用或明确不足；选页缺证据时返回 waiting_for_documents
WP7	异常规则与原因分析	已有代码路径	WP5、WP6	rule registry、正反例集、语义守卫记录	规则只触发核查，不直接判定舞弊；业务因果必须有原文支持
WP8	报告、审计与复现	已有代码路径	WP5、WP6、WP7	报告 schema、replay bundle、脱敏样例	冻结输入和保存响应可离线确定性回放；外部模型复跑只比较预定义类别和数值容差
WP9	评测与误差归因	待启动	WP2-WP8	evaluation report、误差分类账	按提取、计算、证据、异常、复现和自动校验分别报告样本量与结果
WP10	干净环境与演示验证	待启动	WP0、WP8、WP9	安装说明、演示脚本、版本/许可证清单、备份包	目标环境完成上传、提取、校验、计算、检索、报告和证据回查；外部模型不可用时可走离线回放

WP4、WP9 和 WP10 是当前最明显的研发缺口。WP0、WP1-WP3、WP5-WP8 已有代码路径或受限样本基础，但这只表示存在可运行路径，不表示已通过全文、多发行人或竞赛级准确率评测。

5.4 关键难点与攻关计划

难点	研发攻关方法	失败处置
数字识别正确但科目、行列或期间关系错误	将金额、结构、单位、期间和来源定位分层校验；原生 PDF 与 OCR 分开对照，Docling 只做结构预处理	保留为候选并要求科目映射、自动校验与测试金标准抽样评估，不升级为严格事实
累计值、单季值、重述值和合并范围混用	在公式入口统一校验期间、主体、口径和报告版本；对累计差分、直接披露冲突和非正基数设置反例	拒算并请求相邻报告、重述说明或相应附注，不用缺失值补零
审计意见文字变体导致准入误判	保留审计意见原文，同时建立“无保留、保留、否定、无法确认”等规范化标签；严格准入只使用已登记的规范值	无法确认或非标准意见不静默丢弃，转为风险披露或受限计算；先修正规范化再进入高保证通路

难点	研发攻关方法	失败处置
长报告证据未进入当前模型窗口	先在本地保存全文、文本块和事实，再按子问题调用受限检索；记录实际发送范围和召回版本	只报告当前证据边界并提出补件，不把检索未命中写成全文未披露
模型因果越界或协议字段错误	原始响应、工具轨迹和拒绝原因全部留痕；使用固定 schema、有限重试和语义守卫	拒绝候选，必要时只重交失败任务，不静默改写模型原话
自动校验误放/误拒缺少测试金标准样本	按格式、单位、期间、口径、勾稽、来源和置信度建立规则，并登记边界样本	保留 needs_review，按测试金标准抽样评估并将误放/误拒回写规则；测试金标准评估不进入正式运行流程
外部模型、OCR 或检索服务变化	锁定模型/权重/依赖版本，记录配置和发送范围，准备脱敏 replay bundle	外部服务不可用时展示离线回放；把本地确定性回放和模型重新调用分开报告

六 财务分析方法

6.1 统一事实口径

每个金额至少附带公司、报告版本、科目、币种与单位、期间起止、时点/期间属性、合并/母公司口径、原文页码或文本块、提取方法及校验状态。跨报告计算前先核对这些字段。更正稿与原披露保持版本关系，不覆盖原件；追溯重述前后的比较值需要明确采纳哪个披露口径，并保存理由。

6.2 同比与环比

同比使用相同报告期间和相同口径的上年同期或上年全年值。季度报告中的累计金额不能直接当成单季金额：若报告提供年初至今累计值，试验通路按 Q2 = 半年累计 - Q1，Q3 = 前三季度累计 - 半年累计，Q4 = 全年累计 - 前三季度累计推导单季期间流量，再与上一单季比较。存量科目是时点值，不通过累计差分转换。环比计算前需检查前期金额是否为零、负值或口径变化；不适宜计算百分比时展示金额变化并说明原因，不输出误导性百分比。

季度派生设计包含累计差分、单季环比/同比、直接披露冲突校验和非正基数拒算。跨报告差分仅在用户显式联合报告时执行；当前尚不能独立剔除合并范围和政策变化的影响。未通过自动校验的金额和计算，报告必须明确标记为候选或受限结果，全文、多发行人和重述案例纳入后续评测。

6.3 非经常性损益与会计口径

目标数据模型按公司披露表逐项保存非经常性损益的税前构成、所得税影响、少数股东影响和净额，不用模型概括替代原表。当税项、少数股东影响、跨页续表或归母桥接缺失时，保留候选并阻断严格准入。归母净利润与扣除非经常性损益后归母净利润仅在公司、期间、单位和口径一致时比较。若项目表不完整、跨页续表缺失或合计勾稽不一致，则指出缺少行、页或附注，不以空值或未检索到充当零。

会计政策与估计变化、前期差错及追溯重述、同一控制下企业合并、合并范围变化及持续经营披露分别作为分析主题。报告索引、一般性政策文字或模型未命中不能证明事项不存在；判断需要引用对应附注，材料不在当前选定范围时请求用户补充或确认。

6.4 利润与经营现金流背离

合并口径的经营现金流调节使用合并净利润，包含归属于母公司和少数股东的损益；归母净利润另外列示，用于股东收益分析，不能直接替代调节表起点。程序列示相同公司、期间及合并范围的净利润和经营活动现金流量净额、现金利润比、符号及期间变化，并在可验证的表格边界内读取和核验调节项；完整间接法调节表作为后续评测项。现金流为负或净利润为零、负数时，不机械解释现金利润比等比率。

应收款、存货、应付款、折旧摊销等调节项能够解释会计利润与现金流之间的数值桥接，但不能单独证明销售、回款政策、价格或供应链原因。原因分析必须由管理层说明或其他业务附注支持；证据缺失时只呈现量化背离和待补材料，不给出未经证实的业务归因。

6.5 异常信号与结果分类

异常分析同时考虑可计算信号和文本披露风险。异常分析设计包含利润与 CFO 变化方向的比较信号，以及非经常性损益贡献计算；收入与应收项目变化、费用和毛利率异常的自动规则与阈值属于后续扩展及评测范围。信号只触发核查任务，不直接等同舞弊或经营恶化。文本风险必须由披露原文支持，例如审计意见、持续经营重大不确定性或重述事项。

输出中的公司披露是逐字或受控摘录；程序计算附公式和输入；分析推断说明推理依据与限制；证据不足列明尚需材料。质量状态回答“输入及处理能否进入分析”，不能代替“公司是否存在财务异常”的判断。

七 项目特点

7.1 与传统方案的区别

与传统“整本报告喂给 LLM 后总结”相比，FinReport 的差异是：事实先自动校验再计算，计算与解释分离，按子问题取证而非一次性填满上下文，不确定性作为正式结果，运行证据可离线回放。该路线不以模型生成替代程序计算，也不以质量检查通过替代财务异常判断。

7.2 项目特点

1. **先自动校验事实，再做严格计算。**
   OCR、文字提取和表格解析先生成候选，来源映射和校验状态随值传递，模型不能跳过事实准入。
2. **结构化数值与叙述证据分开保存。** 严格公式读取自动校验通过的事实，候选演算另带待校验标记；解释性附注通过有版本和来源的文本块检索，不把长篇全文压缩为一段摘要后丢失可追溯依据。
3. **按问题取证，而非一次性填满上下文。** 受控 Agent 可以根据未解决的子问题读取相关页、文本块和计算结果，也可以请求特定报告或附注。工具范围受限，不允许模型任意访问路径、SQL 或系统命令。
4. **把不确定性作为正式结果。** 对未通过自动校验、口径不匹配、数据不足或因果证据缺失分别保留状态；不把系统降级、检索空结果或质量通过解释为“无异常”。
5. **保留运行证据供离线复现。** 保存原始输入、模型响应、工具交互、版本和哈希。可以离线重放冻结运行；不会据此宣称供应商模型的新一轮调用必然得到相同文本或结论。
6. **研发管理可检查。** 以 WP0-WP10 工作包和 G0-G7 Gate 管理研发，每个 Gate
   提交结果、日志、输入哈希和未通过项；Gate
   通过只表示对应工作包达到退出标准，不代表整份财报或全部金融结论已验收。

八 当前基础与试验结果

8.1 已有实现

- .NET 10 WPF 桌面端、FastAPI API 和基于 uv 的 Python workspace 已形成端到端原型。
- 已支持用户显式选择 pdf_text 或 ocr；原生路径读取文字和坐标，OCR 路径对选定页面图像调用 Baidu Unlimited-OCR。本机 OCR 服务通过 CUDA 与 NF4 运行，不依赖 DeepSeek-OCR。
- 本地 Docling MCP 以关闭 OCR/VLM 的配置为文本结构化预处理；Qdrant MCP 使用真实 CPU embedding，并以 filing_version_id 限制跨报告召回；SQLite 保留权威来源和降级查询。

- 分析 Agent 通过注册工具执行检索、读取文本、查询事实/比较和提出补件请求；独立子命题具备有限重试、候选准入、失败原因和任务恢复记录。
- 测试环境的 Python 测试套件最近一次全量运行结果为 810 passed、12 warnings。该结果验证软件行为，不是财报数据准确率。

8.2 已完成的有限实验

实验	输入与观测	已观察结果	当前可支持范围
Unlimited-OCR 页面抽样	比亚迪 2025 Q1 报告第 2、7 页；逐项对照金额单元格与 PDF 文字层	两页分别匹配 20、70 个金额单元格，未发现缺项或多项	该显卡、固定配置、两张选定页面的金额单元格对照
Qdrant/Docling 抽样	对 2025 Q1、H1、Q3、年报各取一页转换、索引、带报告 ID 查询，并重复执行	固定版本的选页转换、报告过滤和重复索引可运行	本机选页路径及报告版本过滤
八项财务子命题试验	比亚迪 2025 H1 报告，仅页 [7, 8, 62, 63, 65, 69, 156]，60 个文本块	运行状态 waiting_for_documents；3 项待校验候选、5 项证据不足；部分 CFO 数值可演算	候选保留、期间演算及选页缺件提示；尚无测试金标准评测记录
冻结输入离线回放	保存的请求、供应商原响应、工具轨迹和代码/依赖记录	重复回放两次，结果哈希相同	冻结输入和保存响应下的本地规则处理

上述均为受限验证，不能外推为全文或跨公司准确率、全部表格层级正确、CPU 可运行、生产稳定或外部模型复跑同结论。三项历史候选按本计划术语记为“待校验候选”，未重新调用模型或按新校验状态机评测；选页证据不足不代表整份报告未披露。

H1 现金流样例中，本期经营活动现金流量净额为 31,833,471 千元，上年同期为 14,178,310 千元，程序按同期间金额计算增加 17,655,161 千元、同比约 124.5223%。现金流调节表闭合只说明会计桥接关系；业务原因仍须另找证据。试验原始输入与报告哈希、逐轮候选、拒绝理由及回放记录保存在本地实验目录；评测阶段应将可共享的脱敏样例和复现命令整理到评测包中，不把忽略目录中的临时日志直接作为共享材料。

8.3 当前主要差距

差距	当前状态	后续验证
全文覆盖	当前以选定页面和少量检索页为主，不能据此推断整份报告未披露事项	扩展全文 extraction bundle，统计遗漏、来源定位和长文检索覆盖
多发行人	尚未形成跨公司金融 gold 样本，行业模块不标记为 supported	建立至少 5 家发行人保留评测集，按行业和报告类型分别评估
自动校验与测试金标准评估	校验规则和状态模型已有设计，尚无测试金标准评测记录	按测试金标准抽样评估，登记误放、误拒、needs_review 比例并回写规则
演示环境	本地原型可运行，干净环境安装和资源基线尚未完成	按 G7 验证依赖、模型权重、路径选择、回放和资源日志
外部模型复跑	冻结响应可离线确定性回放，不保证重新调用外部模型得到相同语义	对同模型独立运行进行分类一致性和数值容差比较
部署韧性	FastAPI 后台任务尚未等同持久队列或高可用部署	后续研发验证重启、超时、并发限制和失败恢复

九 验证与评测计划

9.1 测试集与金标准

建立经授权的发行人和报告样本集，记录文件 SHA-256、报告版本、页码、期间、合并范围及更正关系。按赛题主线覆盖年报、半年报、季度报告、复杂表格、扫描页、非经常性损益、追溯重述、会计政策/估计、合并范围变化、单位差异、累计与单季换算以及利润现金流背离。测试金标准由评测流程独立标注，仅用于评测；冲突按预先登记规则裁定，不进入正式运行流程。标注结果只用于评估自动校验和模型输出；同一指标需附原文定位、单位、公式和容差。

在至少 5 家发行人完成覆盖样本之前，不将金融模块标记为跨公司 supported。每份报告要区分训练/调试样本与保留评估样本，避免用已调试页面同时报告准确率。

9.2 评测指标

维度	主要指标	验收方式
文档提取	核心指标 exact match、行列/单位/期间匹配率、来源定位正确率、表格遗漏率	与逐页测试金标准标注对照；原生 PDF 与 OCR 分层报告
财务计算	公式值偏差、期间和口径错误数、应拒算案例通过率	独立参考实现重算；零/负基数、重述和累计期间作为反例测试
证据使用	结论引用支持率、未支持断言率、材料命中及遗漏情况	对模型每项事实与因果判断标注证据是否充分
异常识别	精确率、召回率、误报类型及证据定位率	在预先标注的异常和正常样本上评估；没有证据的异常不计为确认发现
可复现性	冻结输入离线回放通过率、日志完整率、跨运行结论分类一致率	首先复放同一保存响应；另对同模型独立运行至少 3 次，仅比较预定义结论类别及数值容差
自动校验与测试金标准评估	自动校验覆盖率、needs_review 比例、误放率、误拒率、测试金标准一致率和规则修正率	按测试金标准抽样评估，仅评估规则，不作为正式运行准入

验收阈值应在金标准数据形成后，由指导教师和项目组根据风险预先登记，不能在看到结果后调整；准确率、召回率和成本均报告样本量与置信边界。尚无完成的金标准结果时，本计划不虚构数值门槛或准确率。

9.2.1 阶段性指标与 Gate 证据

以下是研发目标和验收方法，不是当前成绩。阈值在金标准形成前登记，当前只报告已经测得的样本结果。

维度	阶段目标	Gate 证据
材料完整性	计划样本登记率 100%，哈希/版本关系缺失数为 0	corpus manifest、文件哈希和版本关系图
版本隔离	未显式选择的报告被召回或参与计算次数为 0	跨报告泄漏反例、查询参数和计算输入日志
提取与结构	原生 PDF/OCR 分层报告金额、科目、行列、单位、期间和来源定位指标	双路径 extraction bundle、逐页金标准对照、遗漏分类账
自动校验与测试金标准评估	进入严格计算的事实必须为 auto_passed 且来源可追溯；统计 needs_review 比例、误放率、误拒率和测试金标准一致率	校验规则覆盖、阈值、测试金标准抽样评估及误放/误拒分类账；测试金标准评估仅用于评测

维度	阶段目标	Gate 证据
财务计算	公式偏差、期间/口径错误数和应拒算案例误放率可复算	独立参考实现、零/负基数和累计期间反例；具体准确率待登记
证据与异常	事实、计算和因果断言引用支持率可统计；无证据异常不计为确认发现	obligation trace、规则登记、正反例集和误差分类账
复现与工程	冻结输入/响应离线回放通过数/总数达到 100%；日志字段完整；延迟、token、费用和资源占用实测登记	replay bundle、安装记录、资源/费用日志和演示报告；回放总数以冻结包 manifest 登记为准

9.3 可复现的演示运行

每次评测包包含脱敏或公开样例、输入文件哈希、选择的报告 ID 和页码、uv.lock、OCR/Docling/Qdrant/LLM 版本与配置说明、运行命令、输出报告、结构化结果、校验日志及离线验证脚本。禁止将 API 密钥写进仓库或样例；评测机器无法访问外部模型时，使用保存响应回放模式，并把“离线重放”与“演示环境模型调用”清楚区分。

十 研发实施计划与里程碑

10.1 研发阶段与 Gate

按 G0→G7 顺序推进，具体时间随研发进展调整；Gate 只表示对应研发包的检查节点，不绑定竞赛日期。

Gate	主要工作包	通过条件与可检查证据
G0 基线冻结	WP0	README、计划书、源码版本、输入哈希、配置和现有演示边界一致；冻结输入离线回放可运行
G1 数据与版本	WP1	样本清单、报告类型/期间/更正关系和缺件策略齐全；未选择报告跨版本召回为 0
G2 提取与结构	WP2-WP3	原生 PDF/OCR 路径分层；核心候选可定位到页/块/行列；未闭合表格不进入严格事实
G3 金融计算	WP4-WP5	测试金标准开始闭合；独立参考实现、累计差分、直接披露冲突、零/负基数拒算用例通过
G4 专项与异常	WP5、WP7	非经常性损益和会计变更逐项缺件可追踪；利润-CFO有限信号与后续规则分层登记
G5 Agent 与证据	WP6	子命题工具轨迹、实际发送窗口、引用支持率和补件请求可检查；缺证据返回受限状态
G6 校验与复现	WP4、WP8、WP9	校验日志、测试金标准抽样评估、冻结输入/响应回放和误差分类账可追溯；评测阈值与样本量先登记
G7 演示验证	WP10	干净环境完成上传、路径选择、校验、计算、检索、报告和证据回查；外部模型不可用时可执行回放

每个 Gate 必须同时提交结果、日志、输入哈希和未通过项。Gate 通过只表示对应研发包达到退出标准，不代表整份财报、多发行人或全部金融结论已经验收。

10.2 资源、成本与研发控制

原型复用现有 Windows 开发机及 .NET、Rust、Python 工具链。Unlimited-OCR 已在 RTX 4060 Laptop GPU 上用 CUDA/NF4 完成样页验证；现有记录不代表 CPU 可用或其他设备已验收。Docling 文字预处理与 Qdrant 检索使用本地服务；正式演示需锁定模型权重和依赖来源，并预留文件、索引、页面图像和审计日志空间。

模型费用按实际调用的输入、输出 token 数、供应商计费单位和单价逐笔记录；测试金标准评测工时仅作为评测成本记录，不进入正式运行成本。先冻结选页和输出协议，把同一轮可独立判断的子问题合并测试，只重试失败或缺漏任务；开发回归优先采用离线回放。当前没有经过核验的完整报价或工时基线，因此不编造总预算或收益预测；全文试验前先依据小样本测得的延迟、资源占用与调用费用确认预算。

10.3 研发变更与失败处置

任务延期、模型更换、报告范围扩大或口径规则调整时，先更新版本清单、依赖和影响范围，再重新运行受影响 Gate。外部服务不可用时切换到冻结响应回放；抽取、计算或模型候选失败时保留原始输入和拒绝理由，降级为 needs_review、证据不足或 partial_result，不把自动修补后的文本冒充原始结论。

十一 风险与应对

风险	当前影响	应对方案
PDF/OCR 表格结构错误	金额可能正确但科目、期间或列关系错误	保留原页，执行自动校验、来源映射和测试金标准抽样评估；分别统计金额与结构准确性；拒绝低置信或无法闭合表格
同比/环比口径不一致	累计值、单季值、合并范围或重述值混用会改变结论	计算前执行期间和范围校验；明确派生公式；异常分母或口径不匹配时拒算并说明
长报告证据遗漏	未送入当前上下文的内容可能未被模型使用	以本地保存和按需查询补足；记录查询和发送范围；检索未命中时仅报告当前证据边界
模型生成错误因果	相关性或调节项目可能被写成经营原因	将计算与解释分开；因果句逐条要求原文支持；用语义守卫覆盖已知错误，不宣称通用语义正确
自动校验误放/误拒	错误事实可能进入严格计算，或有效事实被拒收	增加格式、单位、期间、口径、勾稽规则与拒收阈值，保留 needs_review；测试金标准样本仅用于评测；误放/误拒结果用于回写校验规则
外部服务与复现环境变化	模型路由、版本、网络或费用可能变化	冻结模型标识、参数和响应；使用离线回放备份；演示说明外部调用依赖及数据发送范围
第三方许可及数据合规	OCR、检索组件、模型和报告材料有不同来源与授权	在提交清单逐项列明版本、来源、许可证、使用范围、数据授权与密钥管理方式
任务处理与部署韧性	FastAPI 后台任务尚不等于生产级持久队列	后续研发阶段验证任务进程重启、超时、并发限制和失败恢复；未验收前不宣称高可用

十二 结论

FinReport 已有财报导入、候选提取、程序计算、证据检索和分项模型分析原型及有限页面实验。正式版以自动校验通过且来源可追溯作为严格计算准入，下一阶段按 G1-G7 推进，重点不是继续扩展演示页面，而是把自动校验、全文覆盖、多发行人评测、测试金标准评估和演示环境复现做成可检查的 Gate 证据。所有准确性结论以分层评测结果为准；测试金标准评估只用于评估规则，不属于正式运行准入。